

SwimData-IL — שילוב תוצאות איגוד השחייה במסד נתונים יחסי

ניהול נתונים, אוניברסיטת בן-גוריון — אביב 2026 · דוח פרויקט גמר אסף בלילוס ·

<https://github.com/Belilus/swimdata-il> · הגשה 2026-07-27

יחד אורך: עד 5 עמודים. המספרים למטה הופקו מהצינור האמיתי במאגר, מול אליפות אמיתית של האיגוד. גרסה באנגלית: report.md

1. סקירת היישום

SwimData-IL קולט את התוצאות הרשמיות של תחרויות איגוד השחייה בישראל — שמתפרסמות רק כ-PDF — והופך אותן למסד נתונים יחסי מנומל שעונה על שאלות שה-PDF לא יכול: פודיום לכל משחה, טבלת מדליות למועדונים, התקדמות מזמן זינוק לזמן גמר, שיאי קבוצת גיל, ספורטאים רב-משחיים, וניתוח פסילות. אפליקציית מסוף קטנה מריצה את אלה כשאליות עם פרמטרים; לפי המפרט, הדגש הוא על ניהול נתונים, לא על ממשק.

במסד יש שתי אליפויות אמיתיות: מוקדמות אליפות ארנה ישראל קיץ 2026 לגילאים צעירים — דרום (תחרות משני מקורות) ראליפות ישראל נוער ובוגרים חורף 2025 (יורדה ופורסרה מ-loglig) — יחד 4,770 שחיות ב-340 משחים 894 מקצים, שיושבו ל-1,311 שחיינים ב-72 מועדונים, עם אפס מפתחות זרים יתומים. כל תחרות לבדה (למשל 1,701 שחיות / 74 משחים / 496 שחיינים / 39 מועדונים בראשונה) היא מערך שלם; השתיים יחד מוסיפות ממד זהות חוצה-תחרויות (המנגנון קיים; בזוג הזה אין חפיפת שחיינים).

2. מקורות הנתונים

כל הנתונים ציבוריים, דרך isr.org.il/Competitions.ASP, שמקשר לספק התזמון loglig.com. לכל תחרות יש שלושה קובצי PDF:

מקור	שפה	מה הוא תורם
תוצאות	אנגלית	דירוג, מקצה, מסלול, שחיין, שנת לידה, מועדון, זמן גמר, נקודות FINA, סטטוס (.../DNS/DQ)
רשימת זינוק	עברית (מימין לשמאל)	שיוך מסלול, קוד מועדון מספרי, זמן זינוק (או NT), שמות שחיינים ומועדונים בעברית
תקנון	עברית	זכאות, קבוצות גיל, מגבלת משחים — לאימות אילוצים (למשל עד 4 משחים לשחיין; בנתונים המקסימום הוא 4)

ה-PDF הוא דוח עמודות קבועות בלי שכבת נתונים: חילוץ טקסט תמים (pdftotext) מערבב עמודות בגלל כותרות עבריות, רהיטי עמוד שחוזרים, ושמות מועדונים שנשברים על 2-3 שורות. לכן אני מפרסר לפי גיאומטריה — קורא כל מילה עם קואורדינטות (x, y) ב-pdfplumber, משחזר את פסי העמודות, ומעגן כל שחיין על אסימון שנת הלידה, ואז מצמיד כל מילה אחרת לעוגן הקרוב. זה הצעד "נתונים גולמיים → מובנים" שהקורס נפתח בו.

3. אתגרי ניהול הנתונים

האתגר המרכזי הוא פתרון ישויות דרלשוני ממקורות מרובים, יחד עם ערכים חסרים ובעיות פירוס שיוצאות מ-PDF אמיתי.

(א) אינטגרציה בין שפות. התוצאות (אנגלית) ורשימת הזינוק (עברית) חייבות להתאחד לזהות אחת. התובנה: שני הקבצים חולקים את הרביעייה (חתימת משחה, מקצה, מסלול), וברשימת הזינוק יש קוד מועדון מספרי ניטרלי לשפה. חיבור על (מרחק, סגנון, מגדר, גיל, מקצה, מסלול) מתאים 1,672 מתוך 1,701 שורות (98.3%) אחד-לאחד בלי עמימות, ודרך הגשר הזה כל שם/מועדון אנגלי נקשר לעברית ולקוד האיגוד — דטרמיניסטי, לא בתעתיק מטושטש. 29 השורות הנותרות (1.7%) לא נזרקות: זה LEFT JOIN מהתוצאות אל רשימת הזינוק. התוצאות הן עובדת האמת; רשימת הזינוק רק מעשירה. בלי התאמה (משיכה / החלפת מסלול) נשארים NULL בקוד המועדון, בשם העברי ובזמן הזינוק — ערך חסר כנה, לא ניחוש לפי שם. RIGHT JOIN היה שומר נרשמים בלי שורת תוצאות; גרעין הטעינה הוא שורת תוצאה, ולכן נשארים עם LEFT JOIN.

(ב) איחוד מועדונים / קונויצייה. אותו מועדון מאוית בהרבה צורות: הקידומת "מכבי" מופיעה כ-Macabbi / Maccabi

Maccabbi / Macabi; גם הרישיות לא עקבית. קיבוץ לפי שם היה סופר מועדונים יתר על המידה ואפילו מפצל מועדון אחד לשניים. אני מזהה כל מועדון לפי קוד האיגוד ובוחר את השם הקנוני לפי השכיח ביותר (ROW_NUMBER() ...). ושומר כל איות שנצפה בטבלת ביקורת club_name_variant. התוצאה: 72 איות גולמיים מתכווצים ל-39 מועדונים. הצעד הזה גם מרפא פגם בנתונים: אסימון DNF שדלף לתא המועדון יצר את האיות המזויף Maccabi Rishon Seals DNF (פעם אחת) — המוד מוריד אותו לטובת האיות הנקי שנראה 109 פעמים. שלושה מועדוני ירושלים שונים באמת (הפועל, מכבי, Greater Jerusalem) לא מאוחדים, כי הקודים שונים.

(ג) ערכים חסרים ומיוחדים. תוצאה היא או זמן או סטטוס — אף פעם לא שניהם ולא אף אחד — ואכיפה ב-CHECK. זמן זינוק יכול להיעדר (NT) וחייב להישאר NULL, לא אפס; שאילתת השיפור הגדול ביותר לכן מוציאה רשומות NT במקום לתת להן ירידה אינסופית. DNS/DQ/DNF/NS מנורמלים (DQ → DSQ) והפניית חוק FINA (למשל SW 4.4) נשמרת בעמדה נפרדת. בתחרות הראשונה, 6 מועדונים בלי שם אנגלי בכלל — ערך חסר אמיתי, שמטופל בנפילה לשם העברי (COALESCE).

4. תכנון המסד

שני קובצי ה-PDF הם למעשה יחס רחב אחד לא מנורמל, עם כפילות כבדה (שם מועדון ותכונות משחה חוזרים בכל שורת שחיון) ועם אנומליות הכנסה/עדכון/מחיקה הקלאסיות. אני מפרק ל-BCNF: כל תלות פונקציונלית לא טריוויאלית (federation_code → שם מועדון, event_id → מרחק, סגנון, מגדר, גיל, entry_id → result) הופכת לטבלה משלה, כדי שכל עובדה תישמר פעם אחת.

competition → event → heat → entry → result ; swimmer → entry ; club → swimmer ; club → club_name_variant ; ref_stroke → event

החלטות מפתח: club.federation_code הוא מפתח טבעי ייחודי (עוגן הזהות); entry (רשום) result (שח) מפוצלים ל-1-1 כדי שספורטאי שנרשם ולא עלה לזינוק ימודל בכנות; ref_stroke היא טבלת ערכים ולא טקסט חופשי; זמנים נשמרים כאלפיות שנייה שלמות (מדויק, ניתן למיון, ידידותי לאינדקס) ומעוצבים רק בתצוגה. השלמות נאכפת במפתחות ראשיים, שבעה מפתחות זרים, אילוצי, UNIQUE (club.federation_code, heat(event_id, heat_no), entry(heat_id, lane), result.entry_id) entry(heat_id, lane), result.entry_id) אילוצי תחום {25,...,1500} distance_m, מגדר, קודי סטטוס, טווח שנת לידה (1930–2020), וכלל "זמן או סטטוס". האינדקסים נבחרים לפי עומס השאילתות (ראו סעיף 5).

5. שאילתות מייצגות

הסט המלא ב-sql/04_queries.sql; כל שאילתה מסומנת במושג מהקורס. שני דוגמאות:

Q1 — פודיום לכל משחה (פונקציות חלון, לוגיקה תלת-ערכית):

```
SELECT distance_m, stroke, gender, age_group, podium,
       first_name_en, last_name_en, club, final_time
FROM (
  SELECT f.*, RANK() OVER (PARTITION BY event_id ORDER BY final_time_ms) AS podium
  FROM v_fmt f
  WHERE final_time_ms IS NOT NULL -- DSQ/DNS אל מילוכי אל
) t
WHERE podium <= 3;
```

Q3 — דירוג מועדונים (צירוף + אגרציה מותנית):

```
SELECT COALESCE(c.name_en, c.name_he) AS club,
       COUNT(*) FILTER (WHERE r.place = 1) AS gold,
       COUNT(*) FILTER (WHERE r.place = 2) AS silver,
       COUNT(*) FILTER (WHERE r.place = 3) AS bronze,
       COUNT(DISTINCT en.swimmer_id) AS swimmers
FROM result r
JOIN entry en ON en.entry_id = r.entry_id
JOIN swimmer sw ON sw.swimmer_id = en.swimmer_id
JOIN club c ON c.club_id = sw.club_id
```

GROUP BY 1 ORDER BY gold DESC;

שאלות נוספות במאגר: שיפור זינוק→גמר (חשבון בטוח ל-NULL; הירידה הגדולה 48.84 שניות), GROUP BY ... HAVING (מועדונים עם לפחות 10 שחיינים), ביקורת פתרון זהויות (STRING_AGG על club_name_variant), ניתוח פסילות (GROUP BY dsq_rule; SW 4.4 הנפוץ ביותר, 10 פעמים), ו-INTERSECT (שחיינים גם בחופשי וגם בפרפר).

אינדקסים ותוכניות (sql/05_indexes_explain.sql). חיבור להרצאות Server: עץ B+ מורכב, swimmer(last_name, first_name, birth_year) משרת חיפוש לפי קידומת שם (הסדר חשוב); result(final_time_ms) תומך בדירוג / ORDER BY ... LIMIT; עמודות מפתח זר ממאונדקסות כדי שהמייעל יוכל לבחור לולאה מקוננת עם אינדקס במקום לולאה בלוקית בצירוף הכוכב EXPLAIN. DROP INDEX מדגים את השינוי בתוכנית ובעלות.

6. מאגר ושחזור

GitHub: <https://github.com/Belilus/swimdata-il> (קוד, סכימה, SQL, מפרסרים).

bash build.sh מריץ CSV → PDF → אחסון ביניים → ליבה מנורמלת → אימות על DuckDB (בלי שרת); ה-DDL הקנוני מיועד ל-PostgreSQL. האימות בודק ספירות שורות ואפס מפתחות זרים יתומים.